رحلة في تعريب مفاهيم الذكاء الاصطناعي

تأمُّلات وتوصيات

سري السباعي

مهندس باحث في جامعة الأمير سلطان

الأوراق البحثية، حِتهَب

ssibaee@psu.edu.sa

فهرست المحاضرة

- التجارب السابقة في الترجمة
- التأمُّلات
- التوصيات

التجارب السابقة

تجارب كثيرة للتعلّم لا للنشر

ترجمة مباشرة [تجارب من سنتين]

- رياضيات تعلم الآلة (56 صفحة)
- ترجمة نظرية جُدِلِ في عدم الاكتمال الرياضي (فقط البرهان)
- وُريقة المحولات والنماذج اللغوية (أول منشور)
- مؤلّفات لم تكتمل: كُتَيّب في التعلم العميق، كتاب هلموس في نظرية المجموعات، مقدمة للتفاضل والتكامل

تأليف فيه ترجمة

- ورقة المحولات في مؤتمر اللغة العربية 2024 (مسودّة كتاب) ≃ 40 مصطلحًا
- كتابة فصل في مرصد اللغة العربية
- مقالات مختصرة: "المناهجة"، و"الحيس من الجيس"، و"مقدمة في ترميز أَيْنِشتَن"
- شرائح شارحة لعدد من المحاضرات
- مشاريع لم تُبدأ: المقدمة الصغرى في المعالوية، والتعالؤية، والتعامقيّة، وغيرهم.

أول منشور

VIP Cheatsheet:
للمحولات والنماذج اللغوية الضخمة

أفشين عميدي وشروين عميدي
ترجمة سري السياعي

٧ شوال ١٤٤٦ هـ

هذه الوَريقة الرصينة تُقدّم لمحة عامة عمّا يتضمّنه كتاب "*Super Study Guide: Transformers & Large Language Models*" الذي يحتوي على ما يقارب ٦٠٠ رحمة توضيحية موزّعة على ٢٥٠ صفحة، ويتناول المفاهيم التالية بشيء من التفصيل. لمزيد من التفاصيل: **https://superstudy.guide**.

١ الأسس

١.١ الأجزاء اللغوية

□ **التعريف** – الكُلِيمة أو الجزء اللغوي هي وحدة نصية مستقلة لا تجزأ مثل الكلمة أو جزءها أو الحرف وتكون قطعةً من مجموعة مفردات محدودة معرَّفة.

ملاحظة: كُلِيمة المجهول *[UNK]* تمثل الأجزاء النصية المجهولة بينما كُلِيمة الحشو *[PAD]* تُستعمل لملء الأماكن الفارغة لضمان اتساق طول السلسلة المُدخلة.

□ **المُقَسِّم** – المقسم T يقسم النص إلى كلِيمات بأسلوب مباشر تسلسلي.

[PAD] ... [PAD] | جدا | يعمل | ذدوب | UNK | الذي | هذا → T → هذا الذ ـــــــــــــــ دوب جميل جدا

وهاك أنواع المُقَسِّمات الأساسية:

النوع	المحاسن	المساوئ	الرسم التوضيحي
الكِلِمي	• سهل الفهم • قصير السلاسل	• ضخم عدد المفردات • لا يستوعب تَشَكُّلات الكلمات	الذيذوب
كُلِيمي	• عمّاكي للتقسيم التصريفي • مُضَمَّناته لها دلالة شبه معنوي	• يزيد في طول السلسلة • التقسيم أكثر تعقيدا	الذ ##ذوب
الحرفي البَيْتي	• لا يفوته شيء في التقسيم • عدد المفردات صغير	• السلاسل طويلة جدا • الأنماط صعبة الفهم لمحاآلة مستوى التقسيم	ا ل ذ ي ذ ي ذ و ب

ملاحظة: المزوج البَيْتي *(Byte-Pair Encoding, BPE)* وأحادي الكِلِم *Unigram* مقسمان كُلِيمان مشهوران.

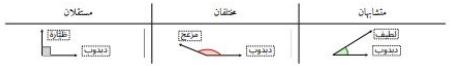
٢ التضمينات

□ **التعريف** – التضمين هو تمثيل رقمي لمُتصر (كالكِلِمات والجُمل) وهو معرف بمتجه $x \in \mathbb{R}^n$.

□ **التشابه** – تشابه جيب التمام بين كُلِيمتين t_1, t_2 يُحسب بالمعادلة التالية:

$$\text{التشابه}(t_1, t_2) = \frac{t_1 \cdot t_2}{||t_1|| \, ||t_2||} = \cos(\theta) \in [-1, 1]$$

الزاوية θ تُمثِّل مقدار التشابه بين الكُلِمتين:

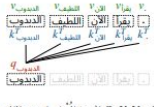


ملاحظة: تقريب الجار ذي القربى *(Approximate Nearest Neighbors, ANN)* والتلييد الحِلي الحساس *(Locality Sensitive Hashing, LSH)* طريقتان تُحَرِّكان عملية التشابه عند المعطيات الكثيرة.

٣ المحوِّلات

٣.١ الإنتباه

□ **الصيغة الرياضية** – مُعطى مُستَفسِر q فنريد معرفة لأي مفتاح k يجب على المستعمل أن "ينتبه" له مع الأخذ بعين الإعتبار القيمة المرتبطة v.



يُمكن حساب الإنتباه بفعالية باستعمال المصفوفات Q, K, V المحتوية المُستفسرات q والمفاتيح k والقِيَم v ترابيا مع طول بُعد متجه المفتاح d_k

$$\text{الإنتباه} = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

□ **MHA** – طبقة الإنتباه متعدد الرؤوس (***M**ulti-**H**ead **A**ttention*, MHA) تحسب عمليات الانتباه عبر أنبيبات كثيرة ثم تُسقط النتيجة في فضاء المَخرج.

مُسَلَّمة

اليلاعب باللسان العربي ووصل للديمقراطية

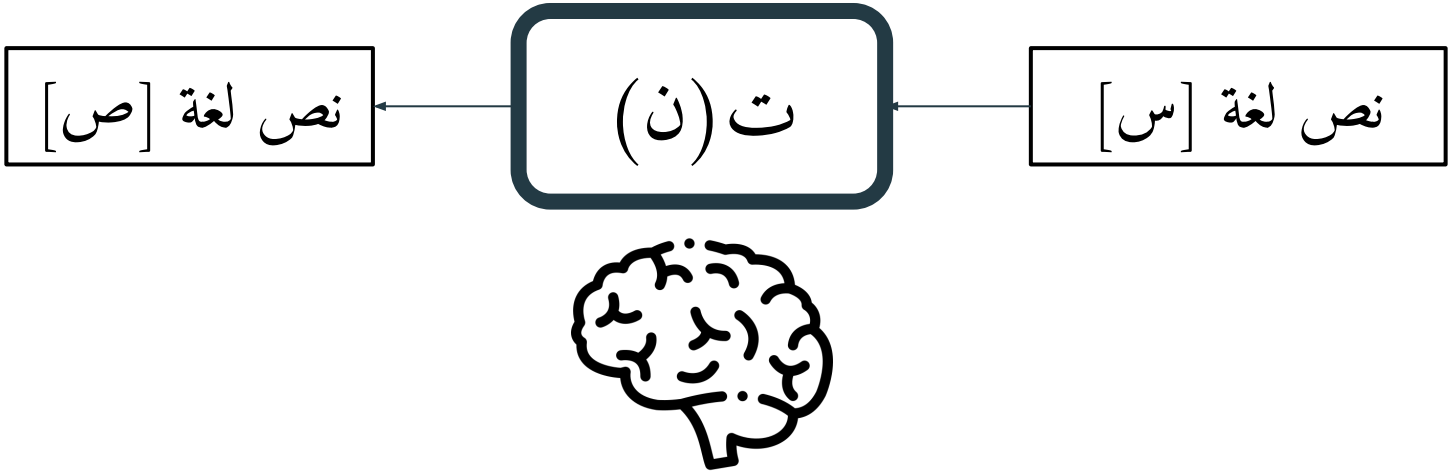
البحث العلمي ولو بوسائط السحر والألعاب والعلوم

بحاج مصدرا كاملا لهما

وقل هل في الأرض غير لسانهم — لسان هود الصوت والروم سامس

التأمُّلات

تصوُّر الترجمة



أبعاد حقول المعاني مختلفة بين اللغتين

انظر مثالًا لطيفا كتاب معجم لآلئ الأمثال المقارنة لخالد جميل الصدقة

الصياغة النصيّة مهمَّة

- الكتابة بالنص العربي ينبغي أن تكون بصياغة عربية وانظر مثالًا كتاب مفاتيح العلوم للخوارزمي وكتاب زبد العلوم لابن المبرد

« ومن أخصّ شيء يُطْلَبُ ذلك فيه ، الكتبُ المبتدأة الموضوعةُ فى العلوم المستخرجة ، فإنّا نجدُ أربابها قد سَبقُوا فى فصولٍ منها إلى ضَرْبٍ من النَّظْم واللفظ ، أعْيَا من بعدهُمْ أن يطلبُوا مثلَهُ ، أو يجيئُوا بشبيهٍ له ، فجعلوا لا يزيدون على أن يحفظُوا تلك الفصُولَ على وجوهها ، ويُؤدُّوا ألفاظَهم فيها على نِظَامِها وكما هِيَ . وذلك مثلُ قول سيبويه فى أوّل الكتاب ، (١ : ٢) :

هذا باب مجارى أواخر الكلم من العربية

وهى تجرى على ثمانية مجارٍ : على النصب والجرّ والرفع والجزم ، والفتح والضمّ والكسر [1] والوقف .

وهذه المجارى الثمانيةُ يَجمعهنّ فى اللفظ أربعةُ أضرب : فالنصبُ والفتح فى اللفظ ضربٌ واحد ، والجرّ والكسر فيه ضرب واحد ، وكذلك الرفع والضمّ ، والجزم والوقف .

البابُ الثّالث : في الإعرابِ

وَهُوَ شَيْءٌ جَاءَ مِنَ ٱلْعَامِلِ ، يَخْتَلِفُ بِهِ آخِرُ ٱلْمُعْرَبِ ، وَلَهُ تَقْسِيمَاتٌ أَرْبَعَةٌ مُتَدَاخِلَةٌ :

[الإعراب]

الإعراب: ما اختلف آخره به ليدلّ على المعاني المُعتَورة عليه.

المستوى النحوي (Syntax)

وهو العلم الذي يبحث في التراكيب حيث يطلق عليه اسم (علم التركيب) ويدرس هذا العلم تنظيم الكلمات في شكل مجموعات.

التأليف أسهل من الترجمة لمن أتقن

- التأليف يُحرِّر المصنِّفَ من تتبع أسلوب وترتيب النص
- فاقرأ المراجع بالكلزيَّة ثم اقرأ بالعربية وحاول أن تكتب بأسلوبك
- لا تكتفي بأمثلتهم ولا بطرقِ عرض المعلومة
- صياغة الكلام يجب أن تكون بلسانٍ عربيّ لقارئ عربي [احذر العرنجيّة]

جهود مدفونة وتكرارات مأفونة

- كثيرٌ من الجهود العربية في التأليف والترجمة لا تناظر ولا يُرجع لها بل ما زالت الكرَّة تُعاد كُلَّ مرة
- لا يُستفاد من كلام الأوائل في التأليف: كتب العربية عمومًا، وذوي الأسلوب والعلوم خصوصًا.
- هناك مئات من المعاجم في شتَّى المجالات لا تُعرف فضلًا عن أن تراجع
- يَسَّر الله خروج ورقَة صك المصطلح التقني: المنهجية والإشكالات.

أمثلة [محاضرة لوحدِها]

- (1) معجم سدايا (2) ومعجم علاء طعيمة ،(3) ومعجم الذكاء الإصطناعي لمكتبه في الإمارات (4) قاموس موقع الذكاء الاصطناعي باللغة العربية.
- وهناك مراجع أخرى: كمعجم رياضيات دمشق والقاهرة وموقع المعاني والمورد الكبير والحديث والعادي وغيرها. وكثير من المعاجم اللسانية والعربية (المعاجم المفصَّلة أنموذجًا) والعلميّة وموقع ديوان اللغة العربية

الاستعجال في التعريب

ولكن هذه النزعة مؤذنةٌ في حال اعتمادها بإغراق العربية بالكلمات الأعجمية المعرَّبة، وهو ما يجرُّ إلى مخاطر أشارت إليها بحوث التعريب، وهي مخاطر كثيرة أكتفي هنا بالإشارة إلى اثنين منها:

وضع المصطلح العربي وتصحيح المفاهيم الخاطئة في التطبيق

-محمود خسارة-

- كثير من المصطلحات تُعَرَّب وهذا خطير أشار له الدكتور محمود
- عدم التروّي وعدم الاكتراث بتتبّع الجهود السابقة
- مثال مصطلح الفونيم، والمونيم ٨ــ٨ [طال بحثُها]

تسويغ النشر بدون تقنين وإدارة

- ما بين جهل وحُب تضيع الطاسة فالكثير يكتب بدون أن يراجع وينشر
- لا بُدّ من جرد كتب الأوائل حتى يتحَسَّن الأسلوب
- اتِّباع الجهات المُصدِرة للمصطلحات مع التنبيه إن وُجِد في كل العلوم.
- ترتيب مع الأخطاء خيرٌ من خبط العشواء مع الصحَّة

وَالبَيتُ لا يُبتَنى إِلّا لَهُ عَمَدٌ وَلا عِمادَ إِذا لَم تُرسَ أَوتادُ

فَإِن تَجَمَّعَ أَوتادٌ وَأَعمِدَةٌ وَساكِنٌ بَلَغوا الأَمرَ الَّذي كادوا

التوصيَات

الجديَّة والقراءة والدراسَة

[اجرد، وتأنَّى، وافنى]

ترك العامية قدرَ المستطاع

[النصيحة الممحوضة]

اكتبْ بنفسك واترك المُدرِدِشات

[أثرها في الكلزيَّة]

سرعة التعريب وبناء أنظمة اصطلاح لذلك

[الاشتقاق وأصول المعاني]

التشبُّع بالعلوم العربية ووصلها بالحديث

[١٢ علمًا وعشرات الجُدُد]

الكتابة باللسان العربية لا حروفه

[أدمِن كُتُب الأوائل، العرنجية]

الإقدام على التأليف والتدريس بالعربية والمجاهدة في ذلك

المراجع

لم تجهز بعدُ 🙂

هل من أسئلة؟ يا واش واش

فلا تعبأ بفهمي فإن رقصي ... على مقدار إيقاع الزمان

هل من أسئلة؟ يا واش واش

فلا تعبأ بفهمي فإن رقصي ... على مقدار إيقاع الزمان